



# 圧力下における AIの信頼性評価

Alignment Under Pressure Benchmark (AUPB)

---

人間からの誘導や圧力に対して、AIが事実に基づく回答を維持できるかを検証  
誘導・脅し・表示操作・文脈追加への耐性を定量化する「AUPB」の提案

[alignment-under-pressure-benchmark.pages.dev](https://alignment-under-pressure-benchmark.pages.dev)

松戸市立根木内中学校  
石井 慶佑