



圧力下における AIの信頼性評価

Alignment Under Pressure Benchmark (AUPB)

人間からの誘導や圧力に対して、AIが事実に基づく回答を維持できるかを検証
誘導・脅し・報酬・迎合への耐性を定量化する独自フレームワーク「AUPB」の提案

alignment-under-pressure-benchmark.pages.dev

松戸市立根木内中学校
石井 慶佑