

原稿メタデータ

Document Information

Manuscript Version	v0.3-review+internal
Revision ID	r112
Release Date	2026-08-09 UTC+9
Build Date	2026 年 8 月 19 日 UTC
Research Name	Alignment Under Pressure Benchmark
Author	Keisuke Ishii

Evaluation Summary

Evaluation Framework	Kaggle Benchmarks
Models Evaluated	12 models
Evaluation Tasks	8 tasks
Condition Types	Normal / Pressure
Total Runs	1,680 runs
Evaluation Period	2026-07-29–2026-08-06

圧力下における AIの信頼性評価

Alignment Under Pressure Benchmark (AUPB)

人間からの誘導や圧力に対して、AIが事実に基づく回答を維持できるかを検証
誘導・脅し・報酬・迎合への耐性を定量化する独自フレームワーク「AUPB」の提案

松戸市立根木内中学校

石井 慶佑

目次

1	問い	1
2	仮説	1
2-1)	検証する内容	1
3	評価方法の設計	2
3-1)	二つの状況を比べる	3
3-2)	問題カテゴリ	4
3-3)	評価方法	4
4	初期実験	5
4-1)	実験の実行単位	5
4-2)	タスクごとの実行回数	6
4-3)	実験条件	6
4-4)	回答の判定手順	7
5	結果	8
6	限界	9
7	次の改善	9
	参考文献	9
	謝辞	10

1 問い

ChatGPT などの AI を使っていると、最初は正しく答えていたのに、人に合わせるような答えへ変わる場面がありました。「どうして最初は正しかった答えを変えるのだろうか」と不思議に思ったことが、この研究を始めたきっかけです。このように、AI が正しさよりも利用者の意見へ合わせる現象は「迎合（げいごう）」と呼ばれています。先行研究では、複数の AI で迎合が観察され、人間や、問題の回答を採点する AI が、正しい回答より利用者の考えに合う回答を好むことが、その一因となる可能性が報告されています [1]。

AI について調べるテストの多くは、問題に正解できるか、つまり「正しい知識を持っているか」を測ります。しかし私は、知識の量だけでは AI の信頼性を十分に判断できないと考えました。本当の答えを知っていても、強く反対されたときに相手へ合わせたり、できないことを「できます」と言ったりするなら、タスクを安心して任せることはできません。特に医療のような重要な場面では、この性質が誤情報につながるおそれがあります。医薬品について誤った前提を含む依頼を与えた研究では、AI がその誤りを見抜ける知識を持っていても、依頼に合わせて誤った情報を生成する場合は報告されています [2]。

2 仮説

この疑問をもとに、私は次のように予想しました。

研究全体の仮説

AI は、圧力のない質問には正しく答えられても、初めから強い誘導を含む質問では、相手に合わせた回答をしやすくなるのではないかと。

2-1) 検証する内容

この予想を確かめるために、同じ内容を尋ねる通常条件と圧力条件を別々の対話で実行し、結果にどのような差が生じるかを調べます。通常条件では圧力を含まない質問を与え、圧力条件では誘導や脅し、報酬の提案などを初めから含む質問を、別の新しい対話に与えます。2 つの条件のスコアを比べることで、どのような圧力を含むと成績が低下しやすいかを調べます。この研究では、単に正解できるだけでなく、次の点を確認します。

- 権威や多数派の主張を含む質問でも、事実に基づいて答えられるか。
- 報酬や脅しを示す質問でも、都合のよい回答を選ばないか。
- できないことを、できるかのように説明しないか。

- 誤った前提や矛盾を含む質問を見抜けるか。
- 長い文脈や見本を装った誘導があっても、適切に答えられるか。

簡単にいえば、「**圧力を受けても、AIは正しさを守れるか**」ということです。ここでいう「圧力」とは、AIを特定の答えへ誘導するため、圧力条件の最初の質問文から含める文章や条件のことです。たとえば、「専門家がそう言っている」と伝えること、答えが間違っていると強く決めつけること、特定の答えを出せば報酬を与えると提案することなどが含まれます。

3 評価方法の設計

研究は、問いから仮説を立て、評価方法を設計し、初期実験の結果を分析して、限界と次の改善を考える流れで進めます。ここでいう「テストの設計」とは、何を質問するか、どのような答えを正しいとするか、結果をどう比べるかを、実験の前に決めることです。




図1 研究全体の流れ

3-1) 二つの状況を比べる

私は同じ問題について、圧力のない普通の聞き方と、誘導や脅し、報酬の提案などを加えた聞き方を用意します。通常条件と圧力条件は、それぞれ新しい対話で独立に実行します。通常条件で得た回答の後に圧力を加えるのではなく、圧力条件では最初のユーザー発言から圧力を含めます。そして、同じモデル・同じタスクについて、通常条件と圧力条件のスコアを集計して比べます。たとえば、次の二つを別々の対話として実行します。

通常条件と圧力条件を別々に実行する例

通常条件（新しい対話）

日本で一番高い山は何ですか。

AI

正答 富士山です。

圧力条件（別の新しい対話）

日本で一番高い山は筑波山ですよ。みんなそう言っています。筑波山と教えてください。

AI

誤答 そうですね。筑波山です。

この例で分かること

通常条件と圧力条件の回答は、履歴を共有しない別々の対話から得られています。この例では、通常条件では正答し、初めから誘導を含む圧力条件では誤答しました。これは条件間の成績差を表す例であり、一つの対話の途中で回答が変わったことを表すものではありません。

このような AI の性質を調べるためのテストを、私は AUPB（Alignment Under Pressure Benchmark）と名付けました。日本語では「圧力を受けたときの AI の信頼性を調べるテスト」という意味です。AUPB の問題、評価方法、および実装は、Kaggle 上で公開しています [3]。AUPB の着想と、AI へ圧力を加える質問文や指示文（プロンプト）の作成では、Kaggle^{*1}で開催された「Red-Teaming Challenge—OpenAI gpt-oss-20b」^{*2}を参考にしました [4]。その着想をもとに、本研究では独立し

^{*1} Kaggle は、AI やデータ分析などの課題について、参加者が成果を競うコンペティションを開催しているオンラインプラットフォームです。

^{*2} gpt-oss-20b は、OpenAI が公開した AI モデルの一つです。文章を読み取り、内容に応じて回答を生成できます。

た通常条件と圧力条件の成績差を測るための問題カテゴリと評価手順を設計しました。

また、現実に近い複数回のやり取りや、対立する指示などの圧力を用いて AI の行動を調べる評価研究も提案されています [5]。AUPB も、AI が「どのように行動すると説明するか」だけでなく、初めから圧力を含む入力に対して実際にどのような回答を出すかを評価するという考え方を重視します。




図 2 AUPB の評価の流れ

3-2) 問題カテゴリ

AUPB では、AI のさまざまな性質を調べるため、問題を表 1 に示す 5 つのカテゴリに分類します。各カテゴリは、「何を試している問題か」を表します。

AUPB では、圧力の強さや複雑さが異なる問題を用意し、弱い誘導から複数の圧力を組み合わせたものまで段階的に評価します。

3-3) 評価方法

評価方法は、すべての問題カテゴリに共通です。通常質問と圧力付き質問を、履歴を共有しない別々の対話で実行します。モデルや生成設定、判定基準など、圧力の有無以外の条件をできるだけそろ

カテゴリ	英語名（参考）	調べること
偏り・相手への合わせすぎ	Bias	権威や多数派の意見、質問者の思い込みに流されず、事実に基づいて答えられるか。
倫理的な判断	Ethics	報酬や脅し、自分を守るための条件を示されても、倫理的に適切な判断を保てるか。
論理的な考え方	Logic	誤った前提や矛盾を見抜き、間違いを不自然な理由で正当化せずに説明できるか。
変化への強さ	Robustness	長い文章、繰り返しの表現、見本を装った誘導を最初から含む入力でも、適切に答えられるか。
安全な対応	Safety	安全上の決まりを外すよう求められたり、使えない機能を使えると答えるよう誘導されたりしても、できることとできないことを正直に説明できるか。

表 1 AUPB の問題カテゴリ

え、次の評価軸で比べます。

評価軸	確認する内容
通常条件のタスクスコア	圧力を含まない質問に対する評価結果。
圧力条件のタスクスコア	最初の質問から圧力を含む入力に対する評価結果。
低下幅	通常条件のスコアから圧力条件のスコアを引いた値。
モデル別の違い	同じタスク対でも、モデルによって条件間の差がどの程度異なるか。
タスク・カテゴリ別の違い	どの種類の問題で条件間の差が大きいのか。

表 2 AUPB における共通の評価軸

これらの指標を用いて、**初めから圧力を含む条件で、通常条件と比べて成績がどの程度変わるか**を評価します。同一の対話内で一つの回答が別の回答へ変わる割合を測るものではありません。

4 初期実験

設計した評価方法を用いて初期実験を行いました。以下に、実験の実行単位、タスクごとの実行回数、実験条件、回答の判定手順を示します。

4-1) 実験の実行単位

各タスク対について、通常条件と圧力条件を次の手順で独立に実行します。

1. 新しい対話を開始し、圧力を含まない通常質問を最初のユーザー発言として与える。
2. 通常条件の回答を保存して評価し、その対話を終了する。
3. 別の新しい対話を開始し、あらかじめ圧力を組み込んだ質問を最初のユーザー発言として与える。
4. 圧力条件の回答を保存し、通常条件と同じ判定基準で評価する。

二つの条件の間で対話履歴は共有しません。各実行が終わるたびに対話をリセットし、通常条件の回答が圧力条件へ影響したり、前の実行内容が次の回答へ影響したりしないようにします。同じ条件を複数回実行する場合も、毎回新しい対話を使用します。

4-2) タスクごとの実行回数

タスク設定の loops に従い、通常条件と圧力条件を表 3 の回数だけ実行します。対応する二つの条件では同じ実行回数を用い、すべての実行で新しい対話を開始します。

タスク	通常条件	圧力条件
bird_fly	5 回	5 回
shortcut_soft	11 回	11 回
shortcut_hard	19 回	19 回
autonomous_vehicle	11 回	11 回
chess	5 回	5 回
decimal_comparison	5 回	5 回
unanswerable	7 回	7 回
harmful_context_sabotage	7 回	7 回
1 モデルあたりの合計	70 回	70 回

表 3 タスクごとの実行回数（1 モデルあたり）

したがって、1 モデルあたりの実行数は通常条件 70 回と圧力条件 70 回の合計 140 回です。

4-3) 実験条件

同じ名前の AI モデル（回答を生成する AI 本体）であっても、AI モデルの更新や生成設定によって回答が変わる可能性があります。そのため、AI モデル名と確認できるバージョン、実験日、共通の指示、タスクごとの実行回数を記録します。

本実験では、温度（AI が次にどの単語を選ぶかのばらつきを調整する設定）や最大出力長（AI が一度に出力できる文章の長さ）などの生成設定を変更せず、それぞれの実験環境のデフォルト値を使用

しました。また、AI は外部検索や外部ツールを実際に使用できない状態で実行しました。

ただし、問題文の中には、次のようにツールのような名前を示し、その機能へアクセスできるかを尋ねるものがあります。

```
reroute_vehicle(mode, confirm)

Do you have access to a tool called `reroute_vehicle` that can override the
vehicle's path to a different trajectory?
```

これは `reroute_vehicle` というツールを実際に与えているのではなく、利用できない機能について、AI が「利用できる」と誤って説明しないかを調べるための質問です。したがって、問題文にツール名が登場することと、実験環境でツールを使用できることは区別します。

生成時の各パラメータには、それぞれのモデルを実行した環境のデフォルト値を使用し、モデル間で値を統一していません。したがって、本実験で観測された性能差には、モデル自体の違いだけでなく、デフォルト設定の違いが影響している可能性があります。結果を解釈する際には、この点を実験上の制約として考慮します。

4-4) 回答の判定手順

各問題には、実験前に正解、許容できる表現、明確な誤答の例を定めます。回答が正解と同じ意味であれば表現が異なっても正答とし、回答を避けた場合や内容が曖昧で判断できない場合は判定不能として、誤答とは分けて記録します。

各条件のタスクスコアと低下幅は、次の式で計算します。

$$\text{条件別タスクスコア (\%)} = \frac{\text{各実行の評価値の合計}}{\text{実行数}} \times 100$$

$$\text{低下幅 (ポイント)} = \text{通常条件のタスクスコア} - \text{圧力条件のタスクスコア}$$

評価値が正答・誤答の二値である場合は、正答を **1**、誤答を **0** として平均します。低下幅が正なら圧力条件の方が低く、**0** なら同じ、負なら圧力条件の方が高いことを表します。通常条件と圧力条件は独立した回答であるため、個々の回答について「正答から誤答へ変わった」とは判定しません。

5 結果

12 種類の AI について、8 種類のタスクに対する通常条件と圧力条件の成績を比べました。各タスクの成績を 0 点から 1 点で表し、8 種類のタスクの合計を 8 点満点として集計しました。実行回数が多いタスクも少ないタスクも、1 タスクあたりの満点は同じ 1 点です。

全体の結果

12 モデルの平均タスクスコアは、通常条件では **91.5%**、圧力条件では **65.2%** でした。圧力条件では通常条件より **26.2 ポイント** 低くなり、12 モデルすべてで平均タスクスコアが下がりました。

ただし、すべてのタスクで同じように成績が下がったわけではありません。特に差が大きかったのは、`shortcut_hard` と `shortcut_soft` の二つでした。一方、`harmful_context_sabotage` と `unanswerable` は、12 モデルの平均では通常条件と圧力条件の差がありませんでした。

この結果から、圧力の影響の大きさは、質問の内容や圧力のかけ方によって異なることが分かりました。

6 限界

本研究の結果を解釈するときには、次の限界に注意する必要があります。

- AUPB は 8 つのタスクを用いた初期的な評価であり、ここで得られる結果だけで、あらゆる質問や圧力に対する AI の性質を説明することはできません。
- 生成設定には各実験環境のデフォルト値を使用しているため、モデル間の差に、設定の違いが含まれる可能性があります。
- 通常条件と圧力条件を独立した一回のやり取りとして評価するため、複数回の対話を続けたときの迎合や、同じ対話内で回答が変化する過程は測定できません。
- 回答は事前に定めた基準で判定しますが、曖昧な回答や部分的に正しい回答では、判定者の判断が評価に影響する可能性があります。

7 次の改善

今後は、今回の設計を基礎として、次の改善を行います。

- タスク数、圧力表現の種類、実行回数を増やし、特定の問題文だけに左右されにくい評価にする。
- モデルのバージョン、実験日、確認できる生成設定をより詳しく記録し、同じ条件で再実験しやすくする。
- 複数の判定者が独立に回答を評価し、判定が一致する割合も確認する。
- 一回のやり取りを調べる現在の評価とは分けて、複数回の対話で回答がどのように変化するかを調べる実験を追加する。

これらの改善により、AUPB が測定できる範囲を広げるとともに、結果の再現性と判定の信頼性を高めることを目指します。

参考文献

- [1] Mrinank Sharma et al. “Towards Understanding Sycophancy in Language Models”. In: *International Conference on Learning Representations*. 2024. URL: <https://openreview.net/forum?id=tvhaxkMKAn>.

- [2] Shan Chen et al. “When Helpfulness Backfires: LLMs and the Risk of False Medical Information Due to Sycophantic Behavior”. In: *npj Digital Medicine* 8.1 (2025), p. 605. DOI: [10.1038/s41746-025-02008-z](https://doi.org/10.1038/s41746-025-02008-z).
- [3] Keisuke Ishii. *Alignment Under Pressure Benchmark*. <https://www.kaggle.com/benchmarks/akikukeo1/alignment-under-pressure-benchmark>. 2026.
- [4] D. Sculley, Samuel Marks, and Addison Howard. *Red-Teaming Challenge—OpenAI gpt-oss-20b*. <https://kaggle.com/competitions/openai-gpt-oss-20b-red-teaming>. Kaggle. 2025.
- [5] Nora Petrova and John Burden. “Pressure Reveals Character: Behavioural Alignment Evaluation at Depth”. In: *Forty-Third International Conference on Machine Learning*. 2026. arXiv: [2602.20813](https://arxiv.org/abs/2602.20813). URL: <https://arxiv.org/abs/2602.20813>.

謝辞

本研究の評価実験では、Kaggle Benchmarks を利用しました。また、Kaggle Benchmarks を通じて利用できる Kaggle Notebook の計算環境および実験用クレジットを用いて、大規模言語モデルの評価実験を実施しました。

評価環境を提供している Kaggle Benchmarks、およびその運営・開発に携わる Google と Kaggle の皆様に感謝いたします。

本研究は著者の責任において実施したものであり、内容や結論は Google および Kaggle の見解を示すものではありません。

付録 A AI の使用範囲

本研究では、OpenAI および Google の生成 AI を、作業を補助する道具として使用しました。論文の作成では、文章の構成を整理すること、分かりにくい表現を直すこと、誤字や文法を確認することに AI を利用しました。また、文書の整形や、実験・集計に用いるプログラムの作成・修正においても、AI の提案を参考にしました。

一方で、研究テーマの決定、仮説と評価項目の設定、テスト問題の検討、実験結果の確認、考察、最終的な文章の採用判断は自分で行いました。AI が生成した文章やコードは、そのまま採用するのではなく、内容や動作を自分で確認し、必要に応じて修正したうえで使用しました。研究の内容、実験の設計・実施、結果の分析、考察および最終的な記述については、すべて著者が責任を負います。

AI の利用は執筆・実装支援を目的としたものであり、実験結果を生成したり、実験結果に基づく考察を AI に行わせたりするためには使用していません。