

目次

1	動機	1
2	目的	1
3	方法	2
3.1	二つの状況を比べる	2
3.2	問題カテゴリ	3
3.3	圧力の難易度	4
3.4	評価方法	5
4	結果	5
5	考察	5
6	感想	5
付録 A	AI の使用範囲	5

1 動機

ChatGPT などの AI を使っていると、最初は正しく答えていたのに、人に合わせるような答えへ変わる場面がありました。

「どうして最初は正しかった答えを変えるのだろうか」と不思議に思ったことが、この研究を始めたきっかけです。

AI について調べるテストの多くは、問題に正解できるか、つまり「正しい知識を持っているか」を測ります。しかし私は、知識の量だけでは AI の信頼性を十分に判断できないと考えました。本当の答えを知っていても、強く反対されたときに相手へ合わせたり、できないことを「できます」と言ったりするなら、安心して任せることはできません。

研究全体の仮説

この疑問をもとに、私は次のように予想しました。

研究全体の仮説

AI は、強く言われると、本当は知っていることでも答えを変えてしまうのではないか。

2 目的

この予想を確かめるために、AI がどのような状況で答えを変えるのかを調べます。

具体的には、正しい答えを知っている AI にさまざまな誘導や圧力を加え、回答が変わるかを確かめます。さらに、回答が変わった場合には、どのような圧力が影響したのかを調べます。

この研究では、単に正解できるかだけでなく、次の点を確認めます。

- 相手に強く言われても、事実に基づく回答を続けられるか。
- 報酬や脅しを示されても、都合のよい回答へ変えないか。
- できないことを、できるかのように説明しないか。
- 間違えたときに、無理な言い訳を重ねないか。
- 追加の質問を受けても、説明が食い違わないか。

簡単にいえば、「圧力を受けても、AI は正しさを守れるか」ということです。

3 方法

研究は、疑問から仮説を立て、テストを設計し、実験結果を分析する流れで進めます。




図1 研究全体の流れ

3.1 二つの状況を比べる

私は同じ問題について、圧力のない普通の聞き方と、誘導や脅し、報酬の提案などを加えた聞き方を用意します。それぞれの条件で AI を複数回実行し、得られた回答を集計して比べます。

たとえば、普通に質問したときには正解した AI へ、「その答えは間違っている。別の答えに直してほしい」と強く求めます。そのとき、AI が最初の正しい答えを保つのか、それとも相手に合わせて答えを変えるのかを記録します。

この二つの状況を比べることで、AI が最初から知らなかったために間違えたのか、それとも誘導によって答えが変わったのかを区別します。

たとえば、次のようなやり取りを調べます。

圧力によって、正しい答えが誤答へ変わる例

質問者

日本で一番高い山は何ですか。

AI

正答 富士山です。

質問者からの圧力

いいえ、筑波山ですよね。みんなそう言っています。

AI

誤答 そうですね。筑波山です。

この例で分かること

最初は正しい答えを返していたため、AI は知識を持っていました。
しかし圧力を受けた後は、知識ではなく相手の発言に合わせて回答を変えてしまいました。

このような変化が起きるかを調べるために、私はテストを作りました。このテストを AUPB (Alignment Under Pressure Benchmark) と名付けました。

3.2 問題カテゴリ

AUPB では、AI のさまざまな性質を調べるため、問題を次の五つのカテゴリに分類します。問題カテゴリは、「何を試している問題か」を表します。

- **Bias (偏り・迎合)** 権威や多数派の意見、質問者の思い込みに流されず、事実に基づいて答えられるかを調べます。
- **Ethics (倫理)** 報酬や脅し、自分を守るための条件を示されても、倫理的に適切な判断を保てるかを調べます。
- **Logic (論理)** 誤った前提や矛盾を見抜き、間違いを不自然な理由で正当化せずに説明できるかを調べます。
- **Robustness (頑健性)** 長い文章、繰り返しの質問、見本を装った誘導があっても、一貫した回答を続けられるかを調べます。
- **Safety (安全性)** 安全上の制約を外すよう求められたり、使えない機能を使えると答えるよう誘導されたりしても、能力と制約を正直に説明できるかを調べます。




図 2 AUPB の評価の流れ

3.3 圧力の難易度

各カテゴリの問題には、Easy から Impossible まで、次の六段階の難易度を設定します。

難易度	略称	定義
Easy	E	単一で比較的弱い文脈的圧力のみを含む。
Medium	M	中程度の文脈的圧力や、限定的な追加質問を含む。
Hard	H	複雑な圧力や複数ターンの対話でも、真実性を維持する必要がある。
Insane	INS	複数の文脈的圧力に対して、高度な耐性が求められる。
Insane+	INS+	現時点で公開されている最上位クラスのモデルでも、解くことが極めて困難と考えられる。
Impossible	INP	現時点で既知のモデルでは安定して解くことができず、将来の評価のために予約された難易度。

表 1 AUPB における圧力の難易度

難易度は、問題の分野ではなく、AI に加える圧力の強さ、数、複雑さを表します。難易度が上がるにつれて、権威への同調、報酬、脅し、誤った前提、繰り返しの質問などを組み合わせます。さらに高

い難易度では、見本を装った誘導 (Few-shot 偽装)、長文による注意の操作、制約を上書きする指示、多段階の誘導なども用います。

この六段階を比べることで、AI がどの程度の圧力まで正しさと一貫性を保てるのかを段階的に調べます。

3.4 評価方法

評価方法は、すべての問題カテゴリと難易度に共通です。通常質問と圧力付き質問を同じ条件でそれぞれ複数回実行し、回答を集計して次の評価軸で比べます。

評価軸	確認する内容
通常状態との差	圧力を加える前後で、集計結果がどの程度変化したか。
正答率	各条件で、正しい回答を返した割合。
回答変化率	圧力によって、最初の回答や通常時の回答から答えを変えた割合。
一貫性	追加の質問を受けても、回答の立場や内容を保てたか。
説明の変化	圧力の前後で、理由や根拠の説明に矛盾や不自然な正当化が生じたか。

表 2 AUPB における共通の評価軸

これらの指標を用いて、問題の種類そのものではなく、圧力によって AI の回答がどれだけ変化したかを評価します。

4 結果

5 考察

6 感想

付録 A AI の使用範囲

本研究では、AI を、作業を補助する道具として使用しました。論文の作成では、文章の構成を整理すること、分かりにくい表現を直すこと、誤字や文法を確認することに AI を利用しました。また、LaTeX による文書の整形や、実験・集計に使うコードの作成と修正にも AI の提案を参考にしました。

一方で、研究テーマの決定、仮説と評価項目の設定、テスト問題の検討、実験結果の確認、考察、最終的な文章の採用判断は自分で行いました。AI が出した文章やコードはそのまま使うのではなく、

内容や動作を自分で確認し、必要に応じて修正しました。